

Sistema híbrido de recomendación de anime

Trabajo Práctico 2 · Análisis Predictivo Avanzado

Recomendaciones top-10 para usuarios existentes y nuevos

Integrantes

Federico Saroka, Nicolás Kahnlein y Gerónimo Fretes

Problema de negocio

¿Qué diez títulos debería mostrar primero una plataforma a cada usuario?

Un catálogo amplio aumenta las opciones, pero también dificulta el descubrimiento. El objetivo es priorizar anime no observados con mayor afinidad esperada.

Ranking top-10

La interfaz necesita un orden, no una predicción exacta de rating.

Mayor descubrimiento

Mayor interacción

Menor costo de elección

Datos y señal de preferencia

7,8 M

interacciones
originales

12.294

anime en el catálogo
original

1.498

usuarios en la cohorte
final

2.438

anime en la cohorte
final

Interacción positiva = rating explícito ≥ 8

Los ratings -1 no se convierten en positivos, y la ausencia de interacción no se interpreta como rechazo confirmado.

110.025

interacciones positivas finales

Diseño experimental

Split determinístico dentro de cada usuario

Entrenamiento

89.313

Validación

10.356

Test

10.356

El dataset no posee timestamps confiables. Por eso no presentamos la evaluación como temporal.

Validación

Selección de arquitectura, pérdida e hiperparámetros

Test

Evaluación única después de congelar todas las decisiones

Métrica principal

Precision@10

Enfoques comparados

Modelo	Información utilizada	Función
Popularidad	Frecuencia global	Baseline no personalizado
Contenido	Género y tipo	Similitud con el perfil del usuario
Colaborativo	Interacciones usuario–anime	Aprende preferencias latentes
Híbrido	Interacciones + metadatos	Combina señal colaborativa y contenido

2 baselines + 6 modelos neuronales

Colaborativo e híbrido se entrenaron con logistic, BPR y WARP-style hard negative.

Arquitectura híbrida

$$s(u,i) = p_u^T(q_i + \lambda Wx_i) + b_u + b_i + b$$

p_u

Preferencia latente del
usuario

q_i

Representación
colaborativa del anime

Wx_i

Género y tipo proyectados

El score ordena candidatos; no es una probabilidad calibrada.

Objetivos de entrenamiento

Logistic

Separa interacciones positivas de negativos muestreados.

BPR

Busca que el score de un positivo sea mayor que el de un negativo.

WARP-style hard

negative

Busca negativos que violan el margen y concentra el aprendizaje en errores de ranking.

Seleccionado: híbrido + WARP-style hard negative

Implementación inspirada en WARP; no es una reproducción exacta de LightFM.

Selección y optimización

Modelo por defecto

0,0953

Precision@10 de validación

Híbrido + WARP-style

Mejor trial de Optuna

0,0983

Precision@10 de validación

15 trials · Optuna TPE

64 dimensiones · 10 épocas · LR 0,00805 · metadata 0,25 · max sampled 5 · margen 2,0

El conjunto de test permaneció reservado.

Resultados finales

11,5 %

Precision@10

19,6 %

Recall@10

0,190

NDCG@10

66,6 %

Hit Rate@10

Sampled AUC 0,925

Cobertura 36,6 %

Diversidad 0,594

Evaluación sobre test reservado después de congelar arquitectura e hiperparámetros.

Deployment



Usuario existente

Embedding aprendido
Títulos vistos excluidos

Usuario nuevo

Fallback de contenido
Favoritos → género y tipo

El deploy no carga PyTorch ni reentrena el modelo.

<https://fedesaroka-analisis-predictivo-avanzado-app-xmct2f.streamlit.app/>

Acciones de negocio

01 **Página de inicio personalizada**
Priorizar los diez títulos con mayor score.

02 **Onboarding de nuevos usuarios**
Solicitar entre tres y diez anime favoritos.

03 **Experimento A/B**
Comparar personalización contra popularidad.

CTR · inicio de reproducción · finalización · tiempo de consumo · retención

Conclusiones y limitaciones

El sistema transforma historial y metadatos en un ranking personalizado, reproducible y desplegable.

Precision@10: 11,5 %

Hit Rate@10: 66,6 %

Limitaciones

Sin timestamps confiables

Umbral fijo de rating

Métricas offline

Cold-start limitado

Próximo paso: validación mediante A/B testing.